京都大学人工知能研究会
KaiRA
Kyoto univ. AI Research Association

論文紹介 2026/04/07

畳み込みニューラルネットワーク入門

理学部　化学科

知能　太郎

アジェンダ

京都大学人工知能研究会
KaiRA
Kyoto univ. AI Research Association

- 1. はじめに：ANNの課題
- 2. CNNとは？
- 3. CNNの基本構造
- 4. 主要な層の役割
- 5. CNN構築のレシピ
- 6. まとめ

1. はじめに：ANNの課題

京都大学人工知能研究会 KaiRA Kyoto univ. AI Research Association

従来の人工ニューラルネットワーク（ANN）は画像認識に課題がありました

- **画像の高次元性**
  - 高解像度のカラー画像を入力すると、パラメータ数が爆発的に増加
  - 例：64×64ピクセルのカラー画像では、最初の層のニューロン1つに**12,288個**の重みが必要 (64×64×3)
- **過学習 (Overfitting)**
  - パラメータが多すぎると、訓練データに過剰に適合
  - 未知のデータに対する汎化性能が低下するリスク

→ 画像の特性を考慮した、より効率的なアーキテクチャが必要です

2. CNNとは？

京都大学人工知能研究会 KaiRA Kyoto univ. AI Research Association

Convolutional Neural Network (畳み込みニューラルネットワーク) の略称です

- **画像処理に特化したニューラルネットワーク**
  - 入力データが画像であることを前提に設計
  - 生物の視覚野の仕組みにヒントを得ています
- **ANNとの主な違い**
  - ニューロンを3次元（縦・横・深さ）に配置
  - ニューロンは前の層の**一部分（局所領域）**にのみ接続

画像の持つ「空間的な局所性」を活かすことで、パラメータ数を大幅に削減します

3. CNNの基本構造

CNNは主に3種類の層を積み重ねて構成されます

[図: ここにシンプルなCNNアーキテクチャの図を入れる (Figure 2)]

- **畳み込み層 (Convolutional Layer)**
  - 画像からエッジや模様などの局所的な特徴を抽出します
- **プーリング層 (Pooling Layer)**
  - 特徴を維持したまま、データの次元を削減します
- **全結合層 (Fully-connected Layer)**
  - 抽出された特徴を統合し、最終的な分類を行います

畳み込み層: 特徴の抽出

- 学習可能なフィルタ（カーネル）で画像上を走査
- エッジやコーナー等の特徴マップ（Activation Map）を生成
- **パラメータ共有**の仕組みにより、少ないパラメータで学習可能

活性化関数には主にReLU (Rectified Linear Unit) が使われます。

[図: ここに畳み込み演算の図解を入れる (Figure 4)]

カーネルを適用し、特徴を抽出する様子

4. 主要な層の役割 (2/4)

畳み込み層の出力サイズは、以下の式で計算できます

$$\frac{(V - R + 2Z)}{S} + 1$$

- V : 入力ボリュームのサイズ (縦 or 横)
- R: 受容野 (カーネル) のサイズ
- Z: ゼロパディングの量
- S: ストライド (カーネルの移動量)

ハイパーパラメータ (R, Z, S) を調整することで、出力サイズを制御します。

4. 主要な層の役割 (3/4)

プーリング層は、特徴マップを圧縮して計算量を削減します

- **次元削減 (ダウンサンプリング)**
  - 特徴マップの空間的次元（縦・横）を小さくする
  - 計算コストの削減と過学習の抑制に貢献
- **Max-pooling**
  - 領域内の最大値を取る手法が一般的
  - 特徴の微小な位置ずれに対して頑健（位置不変性）になる効果

これにより、より本質的な特徴を保持したまま、効率的な処理が可能になります

4. 主要な層の役割 (4/4)

全結合層は、抽出された特徴から最終的な識別を行います

- **特徴の統合と分類**
  - 畳み込み層・プーリング層で抽出されたすべての特徴を入力
  - 最終的なクラス分類のスコアを出力
- **従来のANNと同じ構造**
  - ニューロンが隣接する層の全てのニューロンと結合

[図: ここにFNNの基本構造図を入れる (Figure 1)]

CNNは何を学習しているのか？

学習済みのフィルタを可視化すると、CNNが捉えている特徴が分かります

[図: ここに学習済みフィルタの可視化画像を入れる (Figure 3)]

- MNIST（手書き数字）データセットで学習したCNNの例
- 最初の畳み込み層は、**エッジやストロークといった低レベルな特徴**を自動で学習していることが分かります
- 層が深くなるにつれて、これらの特徴を組み合わせ、より複雑な特徴（数字のパーツなど）を捉えていきます

5. CNN構築のレシピ

効率的なCNNを構築するための基本的な指針があります

- **基本パターン**
  - 畳み込み層とプーリング層を交互に重ね、最後に全結合層を配置
- **推奨パターン**
  - プーリング層の前に複数の畳み込み層を重ねる
  - より複雑で表現力の高い特徴を抽出可能
  - [図: ここに一般的なCNNアーキテクチャの図を入れる (Figure 5)]
- **Tips**
  - フィルタサイズは小さく（例：3×3)、層を深くする方が性能が良い傾向
  - 入力画像のサイズは2のべき乗（32, 64, 128...）が一般的

6. まとめ

本発表の要点です

- **CNNは画像の特性を活かした効率的なアーキテクチャ**
  - 局所結合とパラメータ共有により、従来のANNのパラメータ爆発問題を解決
- **3つの主要な層で構成**
  - 畳み込み層（特徴抽出）、プーリング層（次元削減）、全結合層（分類）の組み合わせ
- **階層的な特徴学習**
  - 単純な特徴（エッジ）から複雑な特徴（物体のパーツ）へと段階的に学習

本論文は、CNNの基本を理解し、画像認識モデルを構築するための優れた入門となります