論文紹介 2026/04/07

畳み込みニューラルネットワーク入門

理学部　化学科

知能　太郎

アジェンダ

- 1. はじめに：ANNと画像認識の課題
- 2. CNNの基本アーキテクチャ
- 3. 主要な層①：畳み込み層
- 4. 主要な層②：プーリング層と全結合層
- 5. CNNの設計レシピと学習の可視化
- 6. まとめ

1. はじめに：ANNと画像認識の課題

近年、人工ニューラルネットワーク(ANN)は機械学習分野で大きな成功を収めています

従来のANN (全結合型)

- ニューロンが前の層のすべてのニューロンと結合
- 汎用性が高いが、入力データの構造を考慮しない

[図: Figure 1. 全結合型ニューラルネットワーク(FNN)の基本構造]
入力層の各ノードが、隠れ層の全ノードに接続している

画像データへの適用における課題

- 高解像度の画像では、パラメータ数が爆発的に増加
- 膨大な計算コストと**過学習(Overfitting)**のリスク増大

課題：パラメータ数の爆発的な増加

画像の次元が少し大きくなるだけで、パラメータ数は現実的でないほど増大します

例：最初の隠れ層の1つのニューロンが持つ重み(パラメータ)数

MNISTデータセット (28×28, 白黒)	少し大きめのカラー画像 (64×64, RGB)
$28 \times 28 \times 1 = \mathbf{784}$	$64 \times 64 \times 3 = \mathbf{12{,}288}$
(多くのANNで管理可能)	(ネットワーク全体では膨大な数に)

→ この問題を解決するために、画像に特化したアーキテクチャである畳み込みニューラルネットワーク(CNN)が登場しました。

2. CNNの基本アーキテクチャ

CNNは、入力が画像であることを前提とし、その特性を活かした構造を持ちます

[図: Figure 2. MNIST分類のためのシンプルなCNNアーキテクチャ]

CNNは主に3種類の層を積み重ねて構成されます。

1. **畳み込み層 (Convolutional Layer):** 画像から局所的な特徴を抽出
2. **プーリング層 (Pooling Layer):** 特徴マップの次元を削減
3. **全結合層 (Fully-connected Layer):** 抽出された特徴を元に分類

最大の特徴は、入力画像の3次元構造（幅, 高さ, 深さ）を保ったまま処理を進める点です。

3. 主要な層①：畳み込み層 (Convolutional Layer)

CNNの中核を担う層で、学習可能なフィルタを用いて画像の特徴を抽出します

役割:

- 画像のエッジ、コーナー、テクスチャなどの局所的な特徴を検出

[図: Figure 4. 畳み込み演算の図解]
カーネルが入力上を移動しながら、内積を計算し、出力(特徴マップ)を生成する

重要な工夫:

- **局所的結合:**
  ニューロンを前の層の小さな領域にのみ接続
- **パラメータ共有:**
  同じフィルタ(カーネル)を画像全体で使い回す

→ これにより、パラメータ数を劇的に削減

畳み込み層の出力サイズを制御する要素

ハイパーパラメータの設定により、出力される特徴マップの次元を調整します

- **Depth (深さ):**
  - 使用するフィルタの数。出力される特徴マップの数に等しい。
  - どのような特徴を抽出したいかに応じて設定する。
- **Stride (ストライド):**
  - フィルタを移動させる歩幅。
  - ストライドを大きくすると、出力サイズは小さくなる。
- **Zero-padding (ゼロパディング):**
  - 入力画像の周囲を0で埋める処理。
  - 出力サイズの縮小を防いだり、画像の端の特徴を捉えやすくする。

出力サイズの計算式:

4. 主要な層②：プーリング層と全結合層

畳み込み層で抽出した特徴を圧縮し、最終的な分類を行います

プーリング層 (Pooling Layer)

- **役割:** 特徴マップの次元削減 (ダウンサンプリング)
- **効果:**
  - 計算量の削減
  - 特徴の微小な位置ずれに対する頑健性 (位置不変性) の獲得
- **代表例:** Max-pooling
  - 領域内の最大値を取る。
  - 通常、2x2のフィルタをストライド2で適用し、サイズを1/4にする。

全結合層 (Fully-connected Layer)

- **役割:** 最終的な分類スコアの出力
- **構造:**
  - 従来のANNと同じく、すべてのニューロンが結合
  - 畳み込み/プーリング層で抽出された特徴をすべて統合し、クラス分類などを行う

5. CNNの設計レシピ

一般的に、畳み込み層とプーリング層を交互に重ねる構成が基本となります

基本的な設計パターン

- 入力層に近い部分でエッジなどの単純な特徴を学習
- 層が深くなるにつれて、より複雑で抽象的な特徴を学習

[図: Figure 5. 複数の畳み込み層を重ねた、より一般的なCNNアーキテクチャ]

設計のヒント

- **小さなフィルタを深く重ねる:** 3x3のような小さなフィルタを複数重ねることで、パラメータ数を抑えつつ、より表現力の高い特徴を学習できる。
- **[CONV -> ReLU] -> POOL の繰り返し:** 畳み込みと活性化関数(ReLU)をセットにし、プーリングで次元を削減するブロックを繰り返すのが一般的。

CNNは何を学習しているのか？ (学習の可視化)

最初の畳み込み層が学習したフィルタを可視化することで、CNNの挙動を理解できます

[図: Figure 3. MNISTで学習したCNNの最初の畳み込み層のアクティベーション]

この図は、ネットワークが数字の**エッジやストローク、特定の曲線**といった、
画像の基本的な視覚的特徴を**自動で学習**していることを示しています。

6. まとめ

本論文は、CNNの基本的な概念とアーキテクチャを解説しました

1. **効率的なアーキテクチャ**
    - CNNは画像の**空間的局所性**を利用し、「局所的結合」と「パラメータ共有」によってパラメータ数を大幅に削減します。
2. **階層的な特徴抽出**
    - **畳み込み層**・**プーリング層**・**全結合層**を組み合わせることで、画像から単純な特徴（エッジ）から複雑な特徴（オブジェクト）までを階層的に抽出・分類します。
3. **画像認識の強力な基盤**
    - シンプルな構造でありながら高い性能を発揮し、現代の画像認識タスクにおいて不可欠な基本モデルとなっています。