論文紹介 2026/04/07

畳み込みニューラルネットワーク入門

理学部　化学科

知能　太郎

アジェンダ

- 1. はじめに：なぜCNNなのか？
- 2. CNNの全体像
- 3. CNNの主要な構成要素
- 4. CNN構築の基本レシピ
- 5. まとめ

1. はじめに：なぜCNNなのか？

従来のニューラルネットワーク(ANN)には画像認識における課題がありました

従来のANN (全結合型) の課題

- 画像を入力として扱うと、パラメータ数が爆発的に増加する
- **例: 64x64ピクセルのカラー画像**
  - 入力次元: 64 x 64 x 3 = 12,288
  - 最初の隠れ層のニューロン1つだけで **1万以上の重み**が必要
- パラメータが多すぎると、計算コストが増大し、**過学習 (Overfitting)** のリスクが高まる

CNNによる解決策

- CNN (畳み込みニューラルネットワーク) は、画像の特性を活かした特殊なアーキテクチャを持つ
- **局所的な結合**と**パラメータ共有**という仕組みにより、パラメータ数を劇的に削減
- これにより、効率的な学習と高い汎化性能を実現

CNNは、画像認識タスクに特化することで従来のANNの限界を克服します

2. CNNの全体像

入力画像から特徴を抽出し、分類するまでの一連の流れ

CNNは主に**3種類の層**を積み重ねて構成されます。

- **入力層 (Input)**: 画像のピクセル値を保持
- **畳み込み層 (Convolutional Layer)**: 画像から局所的な特徴を抽出
- **プーリング層 (Pooling Layer)**: 特徴マップの次元を削減
- **全結合層 (Fully-connected Layer)**: 抽出された特徴を基に最終的な分類

[図: シンプルなCNNアーキテクチャ (論文 Fig. 2)]

3. CNNの主要な構成要素 (1) 畳み込み層

CNNの核となる、画像から特徴を抽出するための層

役割

- **学習可能なカーネル（フィルタ）**を使い、画像から局所的な特徴（エッジ、コーナー、テクスチャ等）を検出する

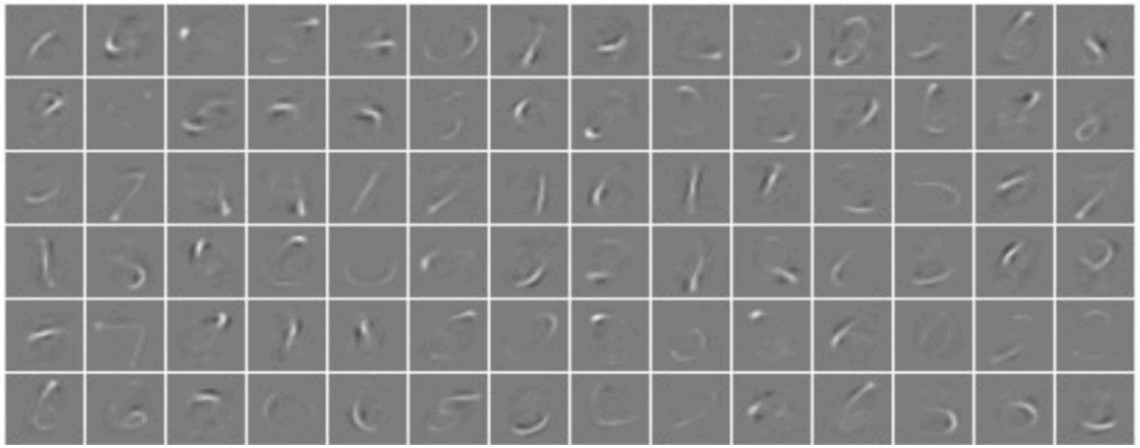

Fig. 3: Activations taken from the first convolutional layer of a simplistic deep

仕組み

- カーネルを入力画像上でスライドさせながら、各位置で内積計算（**畳み込み演算**）を行う
- これにより、特徴の存在箇所をマッピングした**活性化マップ**を生成する

3. CNNの主要な構成要素 (1) 畳み込み層のパラメータ

畳み込み層の挙動を制御する3つの主要なハイパーパラメータ

- **Depth (深さ)**
  - 出力する活性化マップの数（= 使用するカーネルの数）。
  - 様々な種類の特徴を同時に抽出するために設定します。
- **Stride (ストライド)**
  - カーネルをスライドさせる際の移動幅。
  - ストライドを大きくすると、出力される活性化マップのサイズは小さくなります。
- **Zero-padding (ゼロパディング)**
  - 入力画像の周囲を0で埋める処理。
  - これにより、画像の端の特徴を捉えやすくなり、出力サイズの調整も可能になります。

3. CNNの主要な構成要素 (2) プーリング層

特徴マップの次元を削減し、計算負荷を軽減する層

役割

- 特徴マップの空間的な次元（幅と高さ）を削減（**ダウンサンプリング**）する

目的

- ネットワーク全体のパラメータ数と計算量を削減する
- 特徴の微小な位置ずれに対してモデルを頑健にする（**位置不変性**の獲得）

代表的な手法：Max-pooling

- 特徴マップを小さな領域に分割し、各領域の**最大値**のみを取り出す
- 一般的に、2x2のサイズ、ストライド2で適用され、特徴マップのサイズは縦横半分（面積1/4）になる

プーリング層は、特徴マップの最も重要な情報（活性の強い部分）を保持しながら、情報を圧縮します。

3. CNNの主要な構成要素 (3) 全結合層

抽出された特徴を統合し、最終的な分類を行う層

役割

- 畳み込み層とプーリング層で抽出された高レベルな特徴をすべて受け取り、最終的な出力（例：クラスごとの確率）を計算する

構造

- 従来のニューラルネットワーク(ANN)と同様の構造
- 前の層のすべてのニューロンと、現在の層のすべてのニューロンが結合（全結合）している

[図: 従来のニューラルネットワーク構造 (論文 Fig. 1)]

CNNの最終段は、この全結合構造になっていることが多い

CNNは何を学習しているのか？

MNISTデータセットで学習したCNNの最初の層が捉えた特徴の可視化

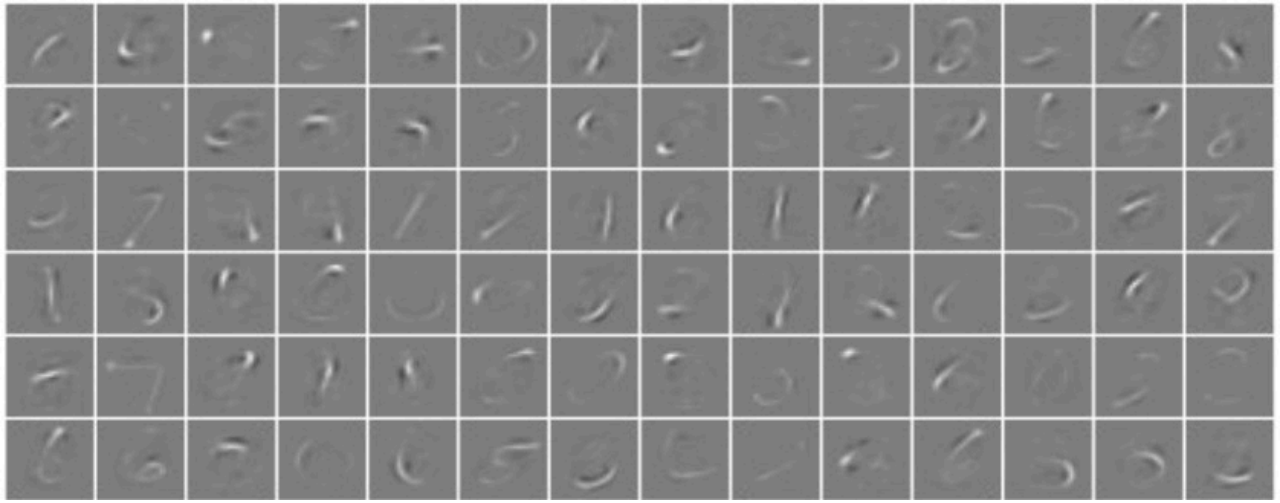

Fig. 3: Activations taken from the first convolutional layer of a simplistic deep

- **CNNは、データから自動で特徴抽出器を学習します。**
  - **浅い層**（入力に近い層）では、エッジや特定の向きの線、色の塊といった**単純で基本的な特徴**を検出するフィルタが学習されます。
  - **深い層**では、浅い層で学習した特徴を組み合わせ、より**複雑で抽象的な特徴**（例：「目」や「鼻」、「数字の丸い部分」など）を捉えるようになります。

4. CNN構築の基本レシピ

効果的なCNNアーキテクチャを設計するための経験的な指針

- **基本パターン**
  - `(CONV -> ReLU) * N -> POOL` というブロックを複数回繰り返すのが一般的。
  - 畳み込み層を複数重ねてからプーリングすることで、より複雑な特徴を捉えられます。
- **推奨される設計**
  - **小さなフィルタを深く重ねる:** 5x5や7x7の大きなフィルタを1層使うより、3x3の小さなフィルタを2層、3層と重ねる方が、パラメータ数を抑えつつ高い表現力を得られることが多いです。
  - **入力画像のサイズ:** 2で繰り返し割り切れるサイズ（例: 32, 64, 96, 224）が望ましいです。
  - **畳み込み層の設定:** ストライドは1、パディングを用いて入力と出力のサイズを維持するのが一般的です。

5. まとめ

本発表の要点

1. **CNNの強み**
   - 従来のANNが画像認識で抱えていたパラメータ数の問題を、**局所的結合**と**パラメータ共有**という仕組みで解決しました。
2. **主要な構成要素の役割**
   - **畳み込み層**で特徴を抽出し、**プーリング層**で情報を圧縮・次元削減し、最後に**全結合層**でクラス分類を行います。
3. **階層的な特徴学習**
   - CNNは層を重ねることで、画像の単純な特徴（エッジ、色）から複雑で抽象的な特徴（物体のパーツ）までを、**データから自動で階層的に学習**する強力なモデルです。